一、 决策树的建立与分类

建立模型与分类过程如下:

1. 将原始数据集转化成 csv 文件并存储为 data.csv

\square	A	В	С	D	E	F
1	id	figure	hair_cold	age	class	
2	1	short	gold	∘ld	1	
3	2	tall	red	old	1	
4	3	tall	gold	old	1	
5	4	short	gold	adult	1	
6	5	tall	black	child	2	
7	6	short	black	old	2	
8	7	tall	black	old	2	
9	8	tall	black	adult	2	
10	9	short	gold	child	2	
11						
12						
13						

2. 读取 csv 数据并序列化

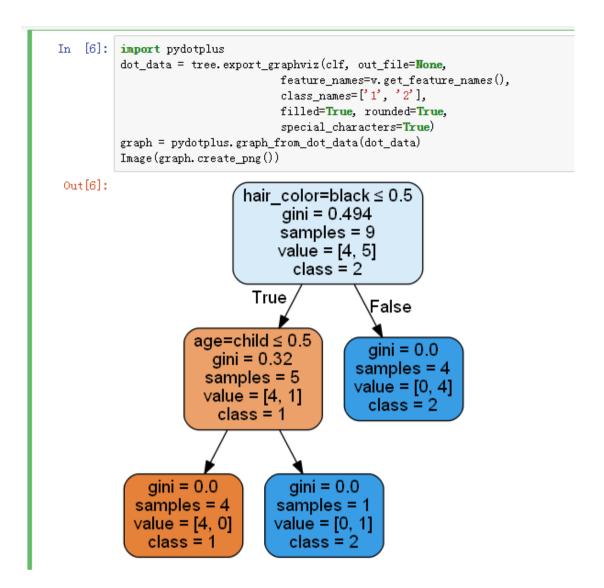
```
In [1]: from sklearn.feature_extraction import DictVectorizer
import cav
from sklearn import tree
from sklearn import preprocessing
from sklearn.mimport pre
```

3. 将特征和类别编码为特征向量

4. 建立决策树,采用 CART 算法。

第一步选取特征为"发色是否为黑色",其 gini 不纯度为 0.494,在所有的特征中最小,若发色为黑色,则分类为第二组,此时 gini 不纯度为 0,该分支可停止;若发色非黑色,则继续询问"年龄是否为儿童",其 jini 不纯度为 0.32,若是儿童则分类为第一组,否则分类为第二组。至此,所有的叶结点的 gini 不纯度均为 0,算法停止。

代码和决策树可视化如下:



5. 分类(矮,黑色,成年)

首先询问"发色是否为黑色",结果为发色是黑色,因此分类为第二组。分类结束。

二、 朴素贝叶斯分类

建立模型与分类过程如下:

代码输出中的所有概率均为取对数结果,采用伯努利离散朴素贝叶斯分类器,所有特征均为二值分布,且相互独立。

先验概率为[4/9,5/9],各个特征的后验概率的对数值可见代码中特征分布的输出。

对给定样本的后验概率分别为:

1/2 * 0 * 1/4 和 2/5 * 4/5 * 1/5 , 因此根据朴素贝叶斯分类器 , 选取最大化后验概率 作为分类结果 , 样本被分到第二组。

三、k-means 聚类

初始化并逐个增加数据点到聚类模型中:

逐渐聚类的类中心和聚类结果如下,聚类的过程为对每个新输入的点根据其距离最近的类中心进行分类,然后归入该类,之后对所有的点迭代重复该操作,直到类中心的变化不超过阈值或到达迭代次数上限:

```
5.]
[[ 6.
[ 0.5 3.5]]
[1 \ 0 \ 1]
[[ 0.66666667 3.
              5.
 [ 6.
                        ]]
[0 1 0 0]
[[ 1. 2.5]
[ 6. 5. ]]
[0 1 0 0 0]
[[ 1.2 2.4]
 [ 6. 5. ]]
[0 1 0 0 0 0]
[[ 1.33333333 2.5
                  ]
```

```
[ 6. 5. ]]
[0 1 0 0 0 0 0]
[[ 1.57142857 2.42857143]
[ 6. 5. ]]
[0 1 0 0 0 0 0 0]
[[ 1.57142857 2.42857143]
[ 5.5 4. ]]
[0 1 0 0 0 0 0 0 1]
[[ 1.57142857 2.42857143]
[ 5. 3.66666667]]
[0 1 0 0 0 0 0 0 1 1]
[[ 1.57142857 2.42857143]
[ 4.75 4. ]]
[0 1 0 0 0 0 0 0 1 1 1]
[[ 1.57142857 2.42857143]
[ 4.8 4. ]]
[0 1 0 0 0 0 0 0 1 1 1 1]
[[ 1.57142857 2.42857143]
[ 4.83333333 4.16666667]]
[0 1 0 0 0 0 0 1 1 1 1 1]
[[ 5. 4.14285714]
[ 1.57142857 2.42857143]]
[1 0 1 1 1 1 1 1 0 0 0 0 0 0]
[[ 1.57142857 2.42857143]
[ 5.125 4.25 ]]
```

对最后的聚类结果进行可视化如下:

```
In [35]:
import matplotlib.pyplot as plt
g1 = np.array([X[i] for i in range(X.shape[0]) if clf.labels_[i] == 0])
g2 = np.array([X[i] for i in range(X.shape[0]) if clf.labels_[i] == 1])
```

```
In [40]: plt.scatter(g1[:, 0], g1[:, 1], marker='x',color='r')
   plt.scatter(g2[:, 0], g2[:, 1], marker='o',color='b')
   plt.scatter([1.57142857, 5.125], [2.42857143, 4.25], marker='^',color='g')
   plt.show()
```

